Predicción de default en préstamos personales

Trabajo Final Integrador

Diplomatura en Ciencia de Datos y Análisis Avanzado - UTN BA

Tomás Di Loreto - Grupo 1

Octubre de 2026

Índice

1. Resumen ejecutivo 2
2. Definición del problema y relevancia 2
3. Datos y metodología 4
4. Modelado y evaluación 6
5. Impacto en el negocio 11
6. Consideraciones éticas y de privacidad 11
7. Conclusiones y recomendaciones 12

Anexos 13

Código y fuentes 15

1. Resumen ejecutivo

Lending Club es una plataforma de préstamos personales de Estados Unidos. A cada préstamo que aprueba le asigna una calificación de riesgo de A (menor riesgo) a G (mayor riesgo), que define su tasa de interés. Un préstamo cae en default cuando el cliente deja de pagarlo. Si se aprobaran todos los préstamos a 36 meses de 2015, la pérdida por defaults sería de 196,5 millones de dólares, el 5,4 % de lo prestado.

Este trabajo construye un modelo que estima la probabilidad de default de cada solicitud con la información disponible el día en que se pide el préstamo. El modelo se compara con una regla que aprueba de la mejor a la peor calificación, aprobando la misma cantidad de solicitudes con las dos. Se entrena con los préstamos a 36 meses otorgados entre 2007 y 2013 y se prueba con los 283.019 otorgados en 2015.

El modelo elegido es un gradient boosting, con un Gini de 0,389 contra 0,357 de la calificación. La ganancia neta es el interés cobrado a los clientes aprobados que pagaron menos la pérdida de los aprobados que cayeron en default.

Solicitudes aprobadas	Ganancia neta con la regla A-G	Ganancia neta con el modelo	Diferencia (intervalo del 95 %)
70 %	183,6 millones de USD	201,6 millones de USD	+18,0 millones de USD (16,5 a 19,6)
80 %	205,8 millones de USD	219,9 millones de USD	+14,1 millones de USD (12,5 a 15,6)
90 %	225,1 millones de USD	233,6 millones de USD	+8,5 millones de USD (7,0 a 9,9)

La pérdida por defaults es prácticamente la misma con las dos reglas. El modelo gana más porque rechaza a clientes de calificación B y C con más riesgo del que indica su tasa, y aprueba en su lugar sobre todo a clientes de calificación C y D con buen perfil, que piden montos más grandes y pagan tasas más altas. La ventaja se repite en los cuatro años probados, de 2012 a 2015.

La recomendación es usar el modelo para decidir qué solicitudes a 36 meses aprobar cuando la plataforma tenga que limitar la cantidad de préstamos.

2. Definición del problema y relevancia

2.1 Contexto del negocio

En Lending Club cada préstamo lo financian inversores. La plataforma aplica primero su política de crédito y después asigna a cada préstamo aprobado una calificación y una tasa de interés acorde a

esa calificación. El equipo de riesgo es el que decide qué solicitudes se aprueban. Al decidir se pueden cometer dos errores con costos distintos.

Si se aprueba a un cliente que después no paga, se pierde en promedio 4.664 dólares por cada préstamo en default, entre los otorgados a 36 meses en 2015.

Si se rechaza a un cliente que iba a pagar, se deja de cobrar el interés de ese préstamo, en promedio 1.800 dólares.

Aprobar a un cliente que no paga cuesta lo mismo que rechazar a 2,6 clientes que sí habrían pagado.

El dataset tiene solo préstamos aprobados, así que no se puede saber cómo habrían pagado las solicitudes que Lending Club rechazó. Por eso la regla A-G de este trabajo es una referencia construida sobre los préstamos aprobados, que ordena de la mejor a la peor calificación, y no la política real de aprobación de Lending Club.

2.2 Objetivo medible

El objetivo, planteado en la pre-entrega, es construir un modelo que estime la probabilidad de default de cada solicitud y que, aprobando la misma cantidad de solicitudes que la regla A-G, cumpla cuatro condiciones sobre préstamos otorgados después de los del entrenamiento. La primera es reducir al menos un 20 % la pérdida por defaults respecto de la regla A-G. La segunda es superar a esa regla en ganancia neta. La tercera es alcanzar un Gini de 0,40 o más, calculado como $2 \times \text{AUC} - 1$ (el coeficiente de Gini de los modelos de crédito, no el índice de Gini de los árboles de decisión). La cuarta es superar a la regresión logística en ganancia neta por al menos un 2 %.

2.3 Hipótesis

La primera hipótesis es que el modelo pierde por defaults al menos un 20 % menos que la regla A-G, y la segunda, que obtiene una ganancia neta mayor, las dos aprobando la misma cantidad de solicitudes.

La tercera hipótesis responde a la devolución de la pre-entrega, que pidió aclarar si el modelo busca reemplazar a la regla A-G o mejorarla. La hipótesis es que el modelo puede decidir sin la calificación, la subcalificación, la tasa de interés y la cuota, que son las variables que ya contienen la evaluación de riesgo de Lending Club. Para probarla se entrenó también una versión del modelo sin esas cuatro variables. Si esa versión funciona igual de bien, el modelo puede decidir sin la calificación. Si solo funciona con esas variables, depende de la calificación y solo la mejora.

2.4 Modelos de referencia

El modelo se compara con tres referencias. La primera es aprobar todas las solicitudes, que es lo que muestra el dataset. La segunda es la regla A-G. La tercera es una regresión logística, que se usa con frecuencia en clasificación de créditos y permite ver el peso de cada variable. Un modelo más complejo, como el gradient boosting o una red neuronal, tiene que superarla por un margen que justifique perder esa facilidad para explicarlo.

3. Datos y metodología

3.1 Fuente y población

La fuente es Lending Club Loan Data, publicado en Kaggle. El archivo de préstamos aprobados tiene 2.260.701 préstamos otorgados entre 2007 y 2018 y 151 columnas. Se cargan 84 columnas, 28 con los datos de la solicitud y del cliente, 53 del buró de crédito y 3 con los pagos que hizo el cliente. El buró de crédito es la empresa que registra el historial financiero de las personas. Las columnas de pagos se usan solo para calcular la ganancia y la pérdida de cada préstamo, nunca como variables del modelo, porque el día de la solicitud no existían.

Se conservan los préstamos terminados, 1.076.751 pagados por completo (Fully Paid) y 268.559 en default (Charged Off), que suman 1.345.310 préstamos con una tasa de default del 19,96 %. De ellos se eliminan 910 (0,07 %) con valores raros, que son los que tienen la relación entre deuda e ingreso vacía, negativa o mayor a 100, o un ingreso anual de cero o menos o de 10 millones de dólares o más. Quedan 1.344.400 préstamos.

3.2 Análisis exploratorio

La tasa de default sube con cada nivel de la calificación, del 5,5 % en la A al 37,5 % en la G. El destino del préstamo también diferencia a los clientes. Los préstamos para pequeñas empresas caen en default en un 24 % de los casos, los préstamos para comprar un auto en un 12 % y los préstamos para pagar la tarjeta de crédito también en alrededor del 12 % (figura 1). La calificación, la subcalificación y la tasa de interés tienen correlaciones de entre 0,95 y 0,98, porque la tasa se fija según la calificación. El ingreso anual es muy asimétrico, con una mediana de 65.000 dólares y valores de hasta 9,5 millones.

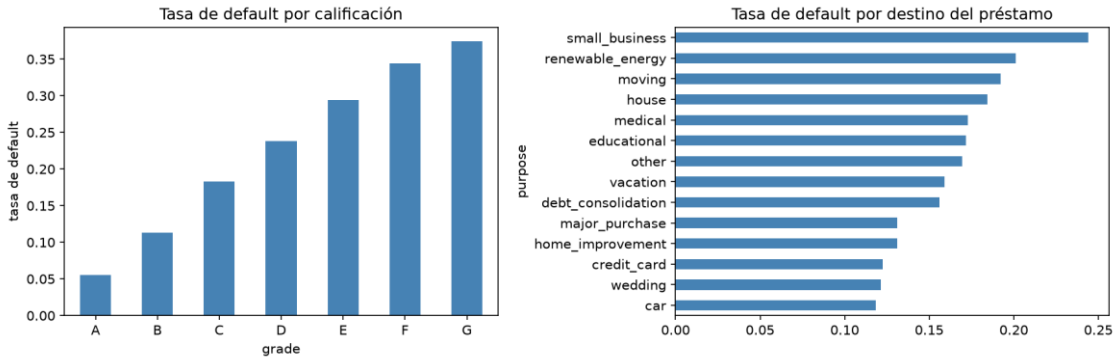


Figura 1. Tasa de default por calificación y por destino del préstamo, en los años que vencieron completos.

Una cohorte es el conjunto de préstamos otorgados en un mismo año. Los datos terminan en diciembre de 2018, así que 2015 es la última cohorte en la que todos los préstamos a 36 meses terminaron. En las cohortes posteriores todavía había préstamos en curso, y entre los terminados quedan sobre todo los que terminaron temprano, por default o por pago anticipado, lo que sesga la tasa de default (20 % en 2016 y 2017, 13 % en 2018). Por eso esas cohortes no se usan (anexo A).

El 14,9 % de los préstamos de 2015 cae en default, un desbalance moderado. No se remuestrean los datos, porque el modelo se usa para ordenar a los clientes por riesgo y la decisión se toma en dinero. La regresión logística y las redes neuronales usan peso de clases, y no se reporta accuracy.

3.3 Preparación de los datos

La antigüedad laboral y la calificación se convierten a escalas numéricas que respetan su orden. La antigüedad laboral no informada se codifica con el valor -1 en lugar de imputarse, porque no informarla se asocia con más default (sección 4.5). Se calcula la antigüedad crediticia del cliente, en años, desde su primera cuenta de crédito hasta la fecha del préstamo. El tipo de vivienda, la verificación del ingreso, el destino y el tipo de solicitud se codifican con one-hot encoding.

Las columnas del buró están casi vacías hasta 2011 y parcialmente completas en 2012, porque Lending Club empezó a registrarlas en esos años. Se conservan 37 de las 53, las que tienen como máximo un 40 % de faltantes desde 2013, y el modelo queda con 46 variables de la solicitud y 37 del buró. El gradient boosting usa los faltantes y los valores extremos tal como están, porque los árboles los aceptan. En la regresión logística y en las redes neuronales los faltantes se reemplazan por la mediana, se agrega una columna que marca dónde faltaba el dato y las variables se escalan con la media y el desvío del entrenamiento. El estado de residencia se descartó (secciones 4.3 y 6).

3.4 Metodología y validación

El trabajo sigue las fases de CRISP-DM, en el orden de las secciones 2 a 5. La validación es temporal y se arma por plazo del préstamo, porque cada plazo tiene su última cohorte completa en un año distinto.

Plazo	Entrenamiento	Validación	Prueba
36 meses	2007 a 2013, 172.988 préstamos, 12,4 % de default	2014, 162.570 préstamos, 13,7 % de default	2015, 283.019 préstamos, 14,9 % de default
60 meses	2010 a 2011, 10.690 préstamos, 22,9 % de default	2012, 9.897 préstamos, 27,7 % de default	2013, 34.382 préstamos, 25,1 % de default

La cohorte de validación se usa para elegir el punto de corte de cada modelo y para comparar modelos y grupos de variables. La cohorte de prueba se usa para medir el resultado final. En 36 meses la tasa de default sube de un período al siguiente, así que el modelo se prueba con clientes más riesgosos que los que vio al entrenar. El análisis principal se hace sobre 36 meses, porque el entrenamiento de 60 meses es chico y casi no tiene buró.

3.5 Métricas

La métrica de decisión es la ganancia neta. La pérdida de un préstamo en default es el monto prestado menos todo lo que el cliente llegó a pagar. Si se aprueban todas las solicitudes a 36 meses de 2015, la ganancia neta es de 237,2 millones de dólares. Como métricas complementarias se reportan el Gini y, para el modelo elegido, la matriz de confusión con la precision, el recall y el F1, contando cada rechazo como una predicción de default.

4. Modelado y evaluación

4.1 La regla A-G como referencia

La regla A-G aprueba de la mejor subcalificación a la peor. Recorriendo los 35 niveles de la subcalificación, de A1 a G5, la ganancia neta crece casi hasta aprobar todas las solicitudes, y en la validación el mejor corte es aprobar prácticamente todo. Lending Club cobra tasas más altas a los clientes de peor calificación, y ese interés adicional cubre los defaults de esos clientes. Por eso la comparación con el modelo se hace a igual tasa de aprobación, donde se ve qué regla elige mejor a quién rechazar.

4.2 Modelos probados

Se compararon cuatro modelos sobre la misma partición y con las mismas variables, sin el estado de residencia. La regresión logística usa peso de clases balanceado. En el gradient boosting

(HistGradientBoostingClassifier) los hiperparámetros se eligieron con GridSearchCV sobre 8 combinaciones, validación cruzada de 3 particiones (aleatoria, no temporal) y AUC como métrica. La combinación elegida tiene una tasa de aprendizaje de 0,05 y hasta 31 hojas por árbol, y el early stopping, con un 10 % del entrenamiento, lo detuvo en 129 árboles. Las dos redes neuronales densas se entrenaron con Keras, con peso de clases y early stopping. La red simple tiene una capa oculta de 16 neuronas y la compleja tiene capas de 64 y 32 neuronas con dropout de 0,3.

Modelo	Gini en validación	Ganancia al 80 % en validación	Gini en prueba	Ganancia al 80 % en prueba
Regla A-G	0,319	151,6 millones de USD	0,357	205,8 millones de USD
Regresión logística	0,351	159,6 millones de USD	0,376	218,1 millones de USD
Gradient boosting	0,372	160,6 millones de USD	0,389	219,9 millones de USD
Red neuronal simple	0,357	159,4 millones de USD	0,382	218,6 millones de USD
Red neuronal compleja	0,366	160,2 millones de USD	0,389	218,6 millones de USD

En los cuatro modelos el punto de corte elegido en la validación fue aprobar casi todo, igual que con la regla A-G, y por eso se comparan aprobando el 80 %. Los cuatro ordenan mejor que la calificación sola, y el gradient boosting tiene el mejor Gini y la mayor ganancia en validación. En prueba su AUC es de 0,695, contra 0,679 de la calificación. Entre los cuatro modelos la ganancia difiere en 2 millones o menos, así que en dinero son equivalentes. El gradient boosting supera a la regresión logística por un 0,6 % en validación y un 0,8 % en prueba, menos que el 2 % fijado en la pre-entrega, y con ese criterio la recomendación sería la logística. Se mantiene el gradient boosting porque en validación ordena mejor (Gini 0,372 contra 0,351) y esa ventaja se repite en prueba (Gini 0,389 contra 0,376). La logística queda como alternativa equivalente en dinero.

4.3 Aporte de cada grupo de variables

Se entrenó el mismo gradient boosting sacando un grupo de variables por vez. La última variante parte del modelo sin estado de residencia y saca además las cuatro variables de la calificación.

Variante	Gini en validación	Ganancia al 80 % en validación	Gini en prueba	Ganancia al 80 % en prueba
Todas las variables	0,374	160,9 millones de USD	0,390	220,1 millones de USD
Sin buró de crédito	0,353	158,5 millones de USD	0,368	215,1 millones de USD
Sin estado de residencia	0,372	160,6 millones de USD	0,389	219,9 millones de USD
Sin estado ni calificación,	0,356	161,4 millones de USD	0,366	219,7 millones de USD

subcalificación, tasa y cuota				

Sacar el buró baja la ganancia en 2,3 millones en validación y 5,0 millones en prueba. Sacar el estado de residencia casi no cambia nada, así que el modelo final no lo usa. Sin las cuatro variables de la calificación, el modelo ordena mejor que la calificación sola (Gini 0,366 contra 0,357) y gana 13,9 millones más que la regla A-G al 80 %, aunque pierde 3,2 millones más por defaults (124,9 contra 121,7 millones). Los datos de la solicitud y del buró alcanzan para decidir la aprobación sin la calificación. El modelo recomendado la usa igual como una variable más.

4.4 Comparación a igual tasa de aprobación

Se ordenó a los clientes de 2015 con la calificación y con el modelo. La curva del modelo queda por encima de la de la regla A-G y al 100 % las dos coinciden, porque ambas aprueban todo (figura 2). Entre el 70 % y el 100 % de aprobación la diferencia se achica a medida que se aprueba más. Un bootstrap de 1.000 remuestreos da intervalos que no incluyen el cero en ninguna de las tres tasas (tabla del resumen ejecutivo).

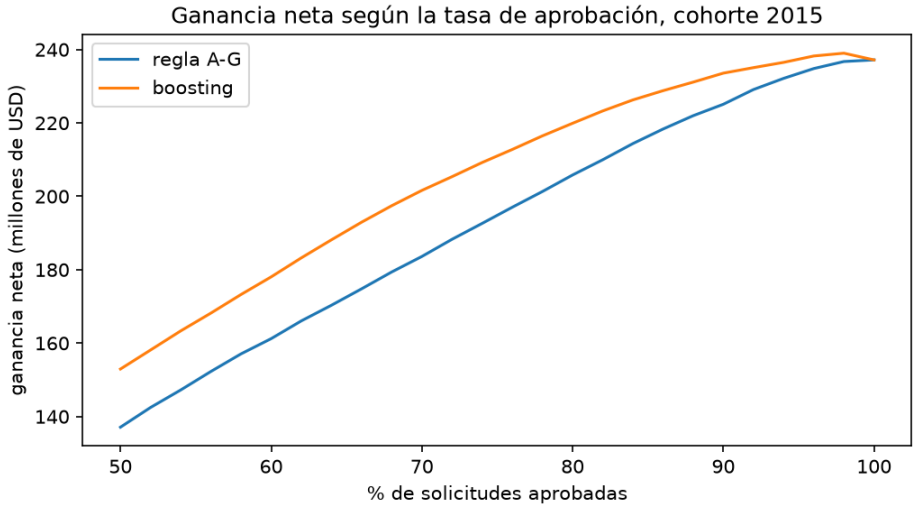


Figura 2. Ganancia neta según el porcentaje de solicitudes aprobadas, cohorte 2015 a 36 meses.

La pérdida por defaults es prácticamente igual con las dos reglas (anexo C). Aprobando el 80 %, hay 19.547 clientes aprobados por la regla A-G y rechazados por el modelo, y otros 19.547 en la situación inversa.

Grupo	Calificaciones	Default	Tasa de interés promedio	Monto promedio	Pérdida por defaults	Interés cobrado
Aprobados por la regla A-G y rechazados por el modelo	83 % C y 17 % B	24,9 %	12,8 %	10.167 USD	18,8 millones de USD	25,3 millones de USD

Rechazados por la regla A-G y aprobados por el modelo	56 % D, 37 % C y 7 % E	19,4 %	15,9 %	12.629 USD	18,7 millones de USD	39,3 millones de USD

El modelo rechaza 1.075 defaults más que la regla A-G, pero los préstamos que aprueba en su lugar son un 24 % más grandes, así que cada default pierde más dinero y la pérdida total no baja. Ese grupo deja 14 millones más de interés, por la tasa y el monto más altos, y de ahí sale la diferencia de ganancia. La regla A-G aprueba todas las A y B, el 83 % de las C y ninguna desde la D, mientras que el modelo elige dentro de cada calificación y aprueba un tercio de las D (figura 5 del anexo C). Separar por plazo y mirar la aprobación por calificación es la segmentación de la base que se analiza en este trabajo.

Al 80 % de aprobación el modelo tiene una precision del 28,8 %, un recall del 38,7 % y un F1 de 0,330 para la clase default, contra 26,9 %, 36,1 % y 0,308 de la regla A-G (anexo C). Rechazar al 20 % de las solicitudes al azar daría una precision del 14,9 % y un recall del 20 %, así que el modelo casi duplica a una regla al azar.

4.5 Importancia de las variables

La importancia por permutación sobre 50.000 préstamos de 2015 pone primero a la tasa de interés, la subcalificación, el ingreso anual, la cantidad de cuentas abiertas en los últimos dos años y el monto pedido. Como la tasa, la calificación y la subcalificación están muy correlacionadas, la importancia se reparte entre ellas y el orden no es exacto. Los valores SHAP (figura 3) muestran en qué dirección mueve cada variable la predicción del modelo, en su escala de salida (log-odds). Son asociaciones que el modelo aprendió, no efectos causales.

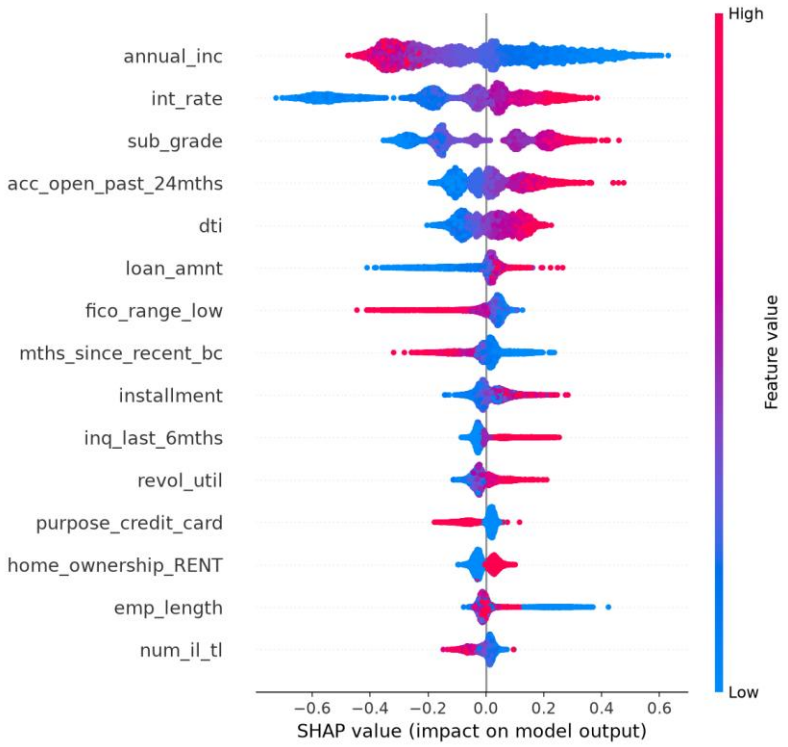


Figura 3. Valores SHAP de las 15 variables más importantes, sobre 5.000 préstamos de 2015.

Además de la calificación y la tasa, el modelo asigna más riesgo a los clientes con ingreso bajo, con una relación alta entre deuda e ingreso o con las tarjetas muy usadas. También a los que abrieron muchas cuentas en los últimos dos años, tuvieron varias consultas a su crédito en los últimos seis meses o abrieron una tarjeta hace poco, que son datos del buró. A los préstamos de monto chico les asigna menos riesgo. En la antigüedad laboral, los clientes que no la informaron tienen los valores SHAP más altos de esa variable, mientras que los que informaron entre 0 y 10 años tienen valores cercanos a cero. Para el equipo de riesgo, esto sugiere revisar con más cuidado las solicitudes que no informan la antigüedad laboral o que tienen varias consultas recientes al buró.

4.6 Sobreajuste, estabilidad en el tiempo y préstamos a 60 meses

El Gini del modelo es de 0,449 en entrenamiento, 0,372 en validación y 0,389 en prueba, una diferencia que muestra algo de sobreajuste y el cambio de los clientes entre años. El modelo subestima la probabilidad de default (11,8 % predicho contra 14,9 % observado en 2015), pero la comparación a igual tasa de aprobación solo usa el orden de los clientes.

Para cada año entre 2012 y 2015 se entrenó el modelo con los años anteriores y se lo probó en ese año, aprobando el 80 %. El modelo supera a la regla A-G en los cuatro años, con un Gini entre 0,045 y 0,053 más alto y una ganancia entre 6,8 y 14,2 millones mayor (anexo B). En 2015, entrenando con todos los años hasta 2014, el Gini llega a 0,409.

En los préstamos a 60 meses, el modelo entrenado con 10.690 préstamos y solo 4 de las 37 columnas del buró tiene un Gini de 0,214, prácticamente igual al de la calificación (0,215), y gana entre 1,6 y 5,9 millones más que la regla A-G (anexo D). Con un orden de riesgo igual al de la calificación y un entrenamiento tan chico, esa diferencia no alcanza para afirmar una mejora en ese plazo.

5. Impacto en el negocio

En la cohorte 2015 a 36 meses se otorgaron 3.624 millones de dólares. Si cada año se otorgara un volumen con un riesgo similar, el modelo agregaría frente a la regla A-G entre 8,5 y 18 millones de ganancia neta por cohorte, según se apruebe entre el 90 % y el 70 % de las solicitudes. Ese beneficio existe solo cuando hay que limitar la cantidad de préstamos, por ejemplo si los inversores no alcanzan a financiar todas las solicitudes.

El Capex y el Opex se estiman como ejercicio, con supuestos simples. El Capex incluye el desarrollo del modelo, las pruebas con el equipo de riesgo y la integración al sistema de aprobación. Asumiendo dos personas durante tres meses con un costo de 5.000 dólares mensuales cada una, el Capex sería de unos 30.000 dólares. El Opex incluye reentrenar el modelo una vez por año, controlar sus resultados con cada cohorte nueva y mantener la infraestructura. Asumiendo una persona dedicada un mes por año y 500 dólares mensuales de servidores, el Opex sería de unos 11.000 dólares por año. Con supuestos de ese orden, el costo es chico frente a una ganancia adicional de 8,5 a 18 millones por cohorte, y bajo esos supuestos el proyecto es rentable.

La ganancia no descuenta el costo de fondeo ni las comisiones de la plataforma, y se cobra a lo largo de los tres años de cada préstamo. El ingreso es declarado por el cliente y no siempre está verificado. El modelo usa solo datos disponibles el día de la solicitud y se puede reentrenar cada vez que vence una cohorte nueva.

6. Consideraciones éticas y de privacidad

El estado de residencia se sacó del modelo porque no mejoraba los resultados (sección 4.3) y porque el lugar donde vive una persona puede reflejar de forma indirecta su origen o su nivel de ingresos, con el riesgo de discriminar sin usar esos datos de forma directa. El ingreso y el tipo de vivienda siguen en el modelo, porque describen la capacidad de pago del cliente. El dataset no tiene datos de edad, sexo ni origen de los clientes, así que no se pudo medir si el modelo aprueba en proporciones distintas a esos grupos. Antes de usarlo habría que hacer esa comparación con datos internos de Lending Club. Los valores SHAP permiten explicarle a cada cliente rechazado qué variables influyeron en su caso.

El dataset es público y no tiene nombres ni datos de contacto de los clientes. El modelo usa solo la información que Lending Club ya recibe con la solicitud.

7. Conclusiones y recomendaciones

Objetivo de la pre-entrega	Resultado	Cumplido
Mayor ganancia neta que la regla A-G a igual aprobación	+14,1 millones aprobando el 80 %	Sí
20 % menos de pérdida por defaults a igual aprobación	Pérdida igual a la de la regla A-G	No
Gini de 0,40 o más	0,389 entrenando hasta 2013, 0,409 entrenando hasta 2014	Parcial
Ganancia neta 2 % mayor que la regresión logística	0,8 % mayor en prueba	No

Sobre la pregunta de la devolución de la pre-entrega, la tercera hipótesis se cumple, porque la versión del modelo sin la calificación gana prácticamente lo mismo que el modelo completo. Igual se recomienda el modelo completo, que usa la calificación como una variable más porque con ella ordena mejor a los clientes (Gini 0,389 contra 0,366), y la calificación sigue fijando la tasa.

La recomendación es usar el gradient boosting sin estado de residencia para decidir qué solicitudes a 36 meses aprobar cuando haya que limitar la cantidad de préstamos. Para los préstamos a 60 meses se mantiene la regla A-G. Como próximos pasos quedan incluir el costo de fondeo en la ganancia, incorporar las solicitudes rechazadas, entrenar el modelo de 60 meses con buró cuando haya cohortes completas posteriores a 2013 y medir las tasas de aprobación por grupo de clientes con datos internos.

Anexos

Anexo A. Tasa de default por año y plazo

Las cifras son de los préstamos terminados, antes de eliminar los 910 préstamos con valores raros. Por eso la cohorte 2015 a 36 meses tiene 283.026 préstamos en esta tabla y 283.019 en el resto del informe.

Año	Préstamos a 36 meses	Default a 36 meses	Préstamos a 60 meses	Default a 60 meses
2013	100.422	12,3 %	34.382	25,1 %
2014	162.570	13,7 %	60.532	31,1 %
2015	283.026	14,9 %	92.519	36,4 %
2016	232.353	19,8 %	60.742	36,4 %
2017	128.538	20,0 %	40.762	32,9 %
2018	41.268	13,2 %	15.043	22,6 %

Anexo B. Estabilidad por año, aprobando el 80 %

Cada año se prueba con un modelo entrenado con todos los años anteriores. La regla A-G desempata al azar a los clientes de una misma subcalificación, y por ese sorteo su ganancia en 2015 da 206,0 millones en esta tabla y 205,8 millones en la sección 4. Las diferencias se calculan con los valores sin redondear.

Año de prueba	Gini del modelo	Gini de la regla A-G	Ganancia del modelo	Ganancia de la regla A-G	Diferencia
2012	0,284	0,239	43,8 millones de USD	36,4 millones de USD	+7,4 millones de USD
2013	0,346	0,298	121,4 millones de USD	114,6 millones de USD	+6,8 millones de USD
2014	0,372	0,319	160,6 millones de USD	151,4 millones de USD	+9,2 millones de USD
2015	0,409	0,357	220,1 millones de USD	206,0 millones de USD	+14,2 millones de USD

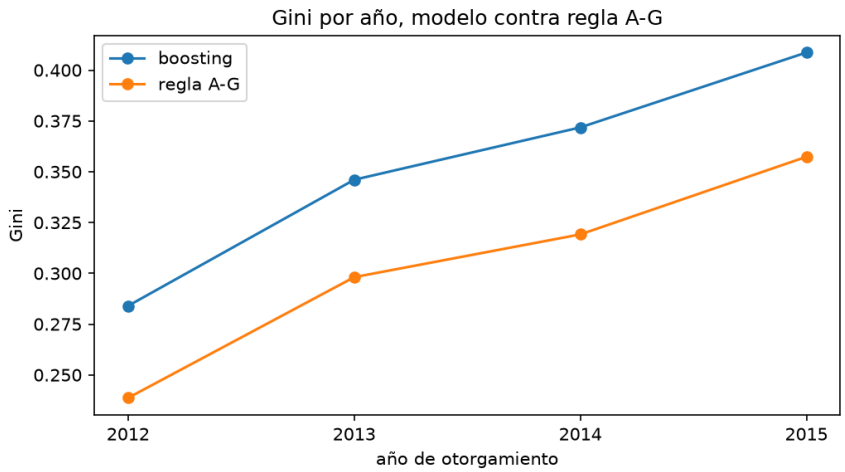


Figura 4. Gini por año de otorgamiento, modelo contra regla A-G.

Anexo C. Detalle de la comparación en la cohorte 2015

Solicitudes aprobadas	Pérdida por defaults con la regla A-G	Pérdida por defaults con el modelo
70 %	95,3 millones de USD	96,3 millones de USD
80 %	121,7 millones de USD	121,6 millones de USD
90 %	152,6 millones de USD	152,8 millones de USD

Matriz de confusión aprobando el 80 % de las solicitudes.

	Regla A-G	Modelo
Defaults rechazados	15.222	16.297
Defaults aprobados	26.909	25.834
Buenos pagadores rechazados	41.382	40.307
Buenos pagadores aprobados	199.506	200.581

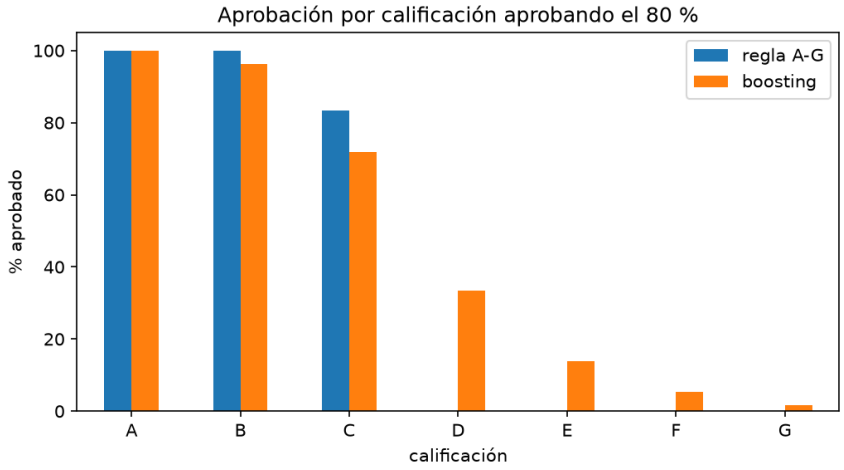


Figura 5. Porcentaje aprobado de cada calificación aprobando el 80 % de las solicitudes.

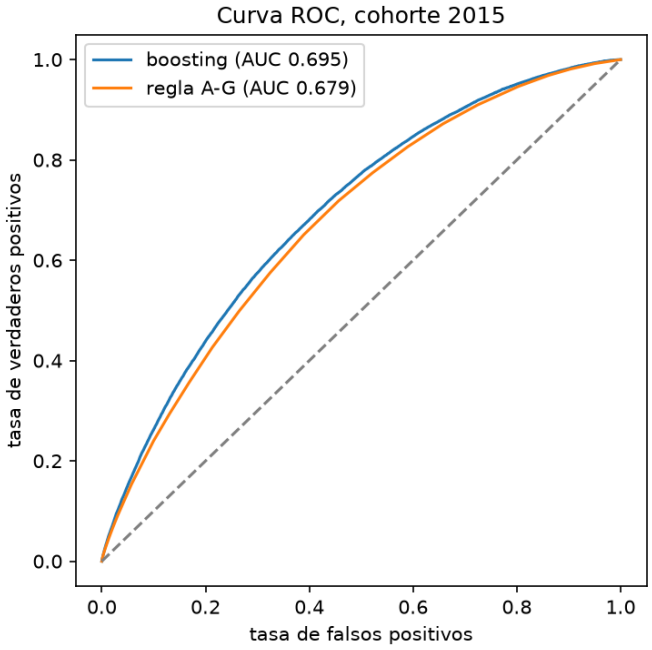


Figura 6. Curva ROC del modelo y de la regla A-G en la cohorte 2015.

Anexo D. Préstamos a 60 meses, cohorte 2013

Solicitudes aprobadas	Ganancia neta con la regla A-G	Ganancia neta con el modelo
70 %	94,2 millones de USD	100,1 millones de USD
80 %	110,5 millones de USD	114,6 millones de USD
90 %	126,6 millones de USD	128,2 millones de USD
100 %	140,3 millones de USD	140,3 millones de USD

Anexo E. Cambios respecto de la pre-entrega

La pre-entrega planteaba una validación cruzada de 5 particiones, y se usaron 3 para reducir el tiempo de la búsqueda de hiperparámetros. La comparación con o sin buró y estado de residencia se hizo solo con el gradient boosting. La comparación contra una partición aleatoria no se repitió, porque la validación temporal por plazo responde mejor la pregunta del negocio. El buró se usó en todos los años, con los faltantes de los años viejos, en lugar de recortar la población a 2013 en adelante.

Código y fuentes

El código está en el repositorio público https://github.com/DiLoretoT/tfi-lending-club, con el notebook TFI_LendingClub.ipynb y las instrucciones para ejecutarlo en el archivo README.

Dataset Lending Club Loan Data, Kaggle.
https://www.kaggle.com/datasets/wordsforthewise/lending-club

Chapman, P. y otros (2000). CRISP-DM 1.0. Step-by-step data mining guide.

Lundberg, S. y Lee, S. (2017). A Unified Approach to Interpreting Model Predictions. Advances in Neural Information Processing Systems 30.

Documentación de scikit-learn (scikit-learn.org), TensorFlow y Keras (tensorflow.org) y SHAP (shap.readthedocs.io).